2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 21

Gimenez, Geronimo

Recayte, Brisa Nicole

Di Marco Garcia, Martin Sebastian

1. Introducción

Contexto de los datos

El siguiente análisis exploratorio tiene como objetivo comprender la estructura de un conjunto de datos clínicos vinculado a la enfermedad renal crónica, la cual es una alteración de carácter progresivo e irreversible y constituye uno de los mayores problemas de salud a nivel global. El dataset contiene 11.933 filas y 29 variables. Cada fila corresponde a un participante de una encuesta poblacional de salud y nutrición realizada en Estados Unidos entre el año 2021 y 2023. Las columnas combinan datos demográficos (edad, sexo, etnia, educación, ingreso), medidas corporales y presión arterial, análisis de sangre y de orina, antecedentes declarados (diabetes y tabaquismo) y variables derivadas (eGFR, ACR, etapa renal y una etiqueta binaria). Para lograr un análisis exploratorio de calidad, vamos a analizar: valores nulos, atípicos y duplicados que nos permitan evaluar la patología y estudiar la interacción entre determinantes sociales y biológicos en el deterioro renal, que sirvan como insumo para el desarrollo de modelos predictivos y estratificación de riesgo. En la sección de “Análisis exploratorio de los datos” detallamos lo que hicimos con valores nulos, atípicos y duplicados, cómo los identificamos a partir de la metadata y como los resolvimos.

Origen de los datos

El origen es casi con seguridad NHANES (National Health and Nutrition Examination Survey), ciclo agosto 2021 – agosto 2023. Le indican el nombre del archivo, al NHANES llevada adelante por el NCHS y combina entrevistas en hogares con exámenes de salud en centros móviles. Después de la suspensión de las operaciones de campo de NHANES en marzo de 2020 debido a la pandemia de COVID-19, la recopilación de datos comenzó para un nuevo ciclo de 2 años en agosto de 2021. Los archivos de datos representativos a nivel nacional de agosto de 2021 a agosto de 2023 se basan en un diseño de muestra actualizado y cuestionarios y procedimientos de examen modificados. En la página web del National Health and Nutrition Examination Survey (NHANES) se puede consultar información adicional sobre la recopilación y el uso de los datos.

Estructura del Repositorio

```
├── CKD_NHANES_2021_2023.csv   # Archivo de datos con variables clínicas y demográficas
├── analisis.ipynb             # Notebook única de Jupyter con el desarrollo del proyecto
├── README.md                  # Guía de instrucciones para ejecución local
├── requirements.txt           # Librerías de Python necesarias para reconstruir el entorno
└── Informe-TPEspecial.pdf     # Informe escrito con hallazgos y conclusiones principales
```

División del análisis por secciones

1. Introducción y Preparación del Entorno

- 1.1. Carga de Librerías: Presentación de librerias utilizadas(pandas, numpy, scipy, seaborn, matplotlib, scikit-learn, statsmodels).
- 1.2. Carga del Dataset: Lectura de la base de datos CKD_NHANES_2021_2023.csv (11.933 filas y 29 columnas).

2. Análisis Exploratorio y Limpieza de Datos (EDA)

- 2.1. Inspección General de la Base: Revisión de la estructura de variables (tipos de datos info()) y resumen estadístico cuantitativo (describe()).
- 2.2. Verificación de Duplicados: Confirmación de registros únicos mediante la clave primaria participant_id.
- 2.3. Diagnóstico y Tratamiento de Valores Faltantes (Nulos):
    - Registros de cuestionario: Mapeo de códigos no informativos (7 y 9 a NaN).
    - Muestras de laboratorio y clínicas: Filtrado por rangos de edad según el protocolo NHANES (sangre en $\geq$ 12 años, presión en $\geq$ 8 años, escolaridad/tabaco en $\geq$ 20 años).
    - Medidas corporales: Evaluación de inconsistencias y verificación de cómputo derivado entre peso, altura e IMC.
- 2.4. Depuración de Inconsistencias: Filtrado de casos inconsistentes en variables clave como la relación Albúmina/Creatinina (ACR) frente a eGFR, e imputación de NaN en casos indeterminados (Unknown en ckd_stage / ckd_present).

3. Planteamiento y Resolución de Hipótesis

3.1. Análisis Univariado

- Hipótesis 1: *"Predomina el sobrepeso en la muestra de la población adulta."*
- Categorización: Clasificación del IMC según estándares de la OMS (Bajo peso, Normopeso, Sobrepeso, Obesidad).
- Resultados: Distribución porcentual mostrando que el exceso de peso (Sobrepeso + Obesidad) representa más del 70% de la muestra.

3.2. Análisis Bivariado

- Hipótesis Bivariada 1: *"La proporción de personas con diabetes es significativamente mayor en estratos de menores ingresos (*$poverty_income_ratio$*)."*
- Validación Estadística: Prueba de Independencia de Chi-cuadrado (χ^2) mostrando significancia estadística ($p < 0.05$).
- Hipótesis Bivariada 2: *"La mayoría de los casos de Enfermedad Renal Crónica (CKD) identificados corresponden a la etnia Blanca No-Hispana."*
- Análisis: Comparativa de distribución de frecuencias de CKD por origen étnico (ethnicity).
- Validación Estadistica: Al igual que la Bivariada 2 usamos la prueba de Independencia de Chi-cuadrado (χ^2) y mostramos la significancia en estadística ($p < 0.05$).
- Hipótesis Bivariada 3: *"La presión arterial es un factor de riesgo del CKD"*
- Análisis: Comparativa de distribución de frecuencias de CKD por presión sistólica(bp_systolic).
- Validación Estadística: Usamos Test U de Mann-Whitney, ya que chequeamos que no se cumple el supuesto de normalidad.

3.3. Análisis Multivariado

- Hipótesis Multivariada 1: *"Existe un vínculo directo entre la edad, sexo, BMI, presión arterial, diabetes, tabaquismo y nivel socioeconómico con la probabilidad de presentar CKD."*
- Hipótesis Multivariada 2: *"Los indicadores de salud física (como el peso y la presión arterial) y los marcadores de análisis de laboratorio (como la función de los riñones) se agrupan en patrones comunes que nos permiten ver qué variables se mueven juntas en la población."*

2. Análisis exploratorio de los datos

El dataset reúne 11.933 personas y 29 variables de la encuesta NHANES 2021-2023 (CDC/NCHS) de la cual encontramos su página web y la añadimos a la bibliografía. El dataset cuenta con datos demográficos, medidas corporales, presión arterial, análisis de sangre y orina, antecedentes declarados y variables derivadas de función renal (eGFR, ACR, etapa de CKD). Casi un tercio de la muestra (3.780 personas, 31,7%) son menores de 18 años. No hay duplicados exactos y "participant_id" es único; al ignorar el ID aparecen 364 filas repetidas, pero son perfiles casi vacíos de menores y no se eliminaron. Los valores nulos son en su mayoría estructurales se deben a la edad (los análisis de sangre se hacen a partir de los 12 años y los de presión a partir de los 8, otros estudios como el nivel de educación o fumadores se hacen a partir de los 20 años), a que la persona no asistió al examen o a saltos del cuestionario. El eGFR falta en 5.607 personas (47%): 2.545 son menores de 12 años, 2.194 no fueron al examen y 868 fueron examinadas sin resultado. Entre las 9.388 personas de 12 años o más, a 3.084 (32,9%) les falta algún dato de sangre y en el 98% de esos casos faltan los ocho, por lo que no se imputaron y cada análisis usa solo los casos completos.

En la limpieza se pasaron a nulo los códigos 7 y 9 de las variables de "cuestionario" y la categoría Unknown de "ckd_stage". Esta última corresponde a eGFR ausente, y "ckd_present", la codificada como 1, estaba mal, pasamos los valores de la columna "ckd_present" a nulo cuando en la misma fila de la columna "ckd_stage" había Unknown , ya que no había presencia de ckd. Otro problema que encontramos fue que había 70 casos donde había ACR nulo y se clasificaron como NO CKD en la columna "ckd_stage", lo cual nosotros lo vimos como una inconsistencia, ya que para clasificar como NO CKD se debe tener ACR < 30. Con respecto a los nulos en las medidas corporales(bmi, height_cm, weight_kg), lo que intentamos hacer es, si tenemos 2 de las 3 medidas, calcular la faltante, ya que bmi es un cálculo entre height_cm y weight_kg. Pero, no hay ningún caso en el dataset donde tengamos 2 medidas y falte 1.

Para hacer las hipótesis consultamos la metadata e información adicional con el objetivo de poder proponer hipótesis de calidad que dado el contexto de la enfermedad renal, pueden tener un valor en cuanto a su utilidad, y con los resultados, se puedan evaluar o tomar medidas.

3. Hipótesis y resolución

3.1. Hipótesis Univariada 1:

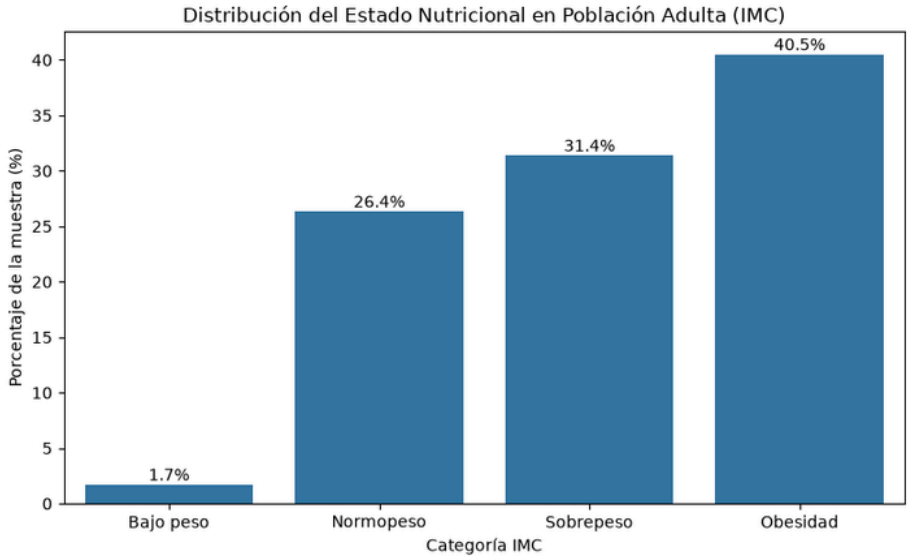
"Predomina el exceso de peso en la muestra"

Operacionalmente, se define que "predomina" si las categorías **sobrepeso** y **obesidad** son más frecuentes y representan frecuencias individuales más altas.

En la documentación del estudio (metadata) se menciona el **exceso de peso** como uno de los factores de riesgo asociados al **deterioro de la función renal**. Probar dicha hipótesis permite evaluar el perfil de vulnerabilidad nutricional de la población estudiada.A nivel sanitario, identificar esta prevalencia aporta evidencia para justificar programas tempranos de prevencion y concientizacion, aplicables tanto a adultos como a edades más tempranas para mitigar afecciones renales crónicas en el largo plazo.

El análisis se implementó seleccionando únicamente los registros correspondientes a individuos adultos para permitir la aplicación directa de los puntos de corte establecidos por la OMS para el índice de Masa Corporal. Se verificó la cantidad de registros con valores nulos para contabilizar las exclusiones y evitar sesgos. Mediante una agrupación se formaron las siguientes categorías:

- Bajo Peso: [0 ; 18,5)
- Normopeso: [18,5 ; 25)
- Sobrepeso: [25 ; 30)
- Obesidad: [30; 80]



A partir de la evidencia empírica observada, la hipótesis se confirma. La obesidad constituye la condición más frecuente en la muestra con un **40,5%** de los casos, seguida por el sobrepeso con un **31,4%**. Agrupando ambas categorías bajo la definición *exceso de peso*, estas representan en conjunto un **71,9%** de la población adulta evaluada. Frente a un **26,4%** de normopeso y apenas un **1,7%** de bajo peso, queda manifestado un predominio contundente del exceso ponderal, lo que fundamenta su relevancia clínica y estadística como factor de riesgo preponderante en el dataset.

3.2. Hipótesis Bivariada 1:

"La proporción de personas con diagnóstico positivo de diabetes (diabetes_diagnosed) es significativamente mayor en los estratos de menor nivel de ingresos (medido a través del poverty_income_ratio)."

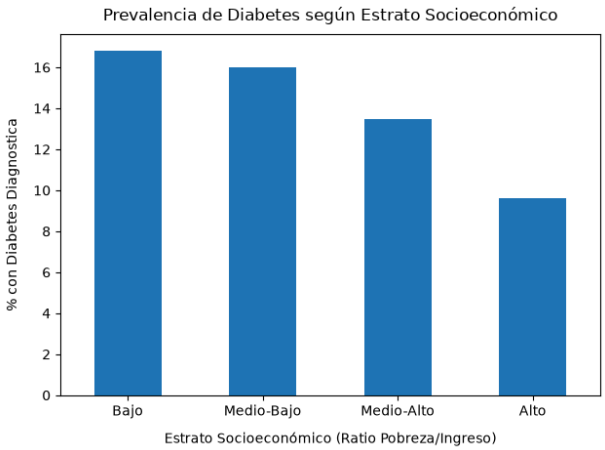
La Motivación es evaluar la equidad en salud y determinar si los estratos socioeconómicamente más vulnerables sufren una mayor carga de enfermedad como la diabetes. Identificar este sesgo permite orientar recursos de prevención a los sectores con menores recursos económicos.

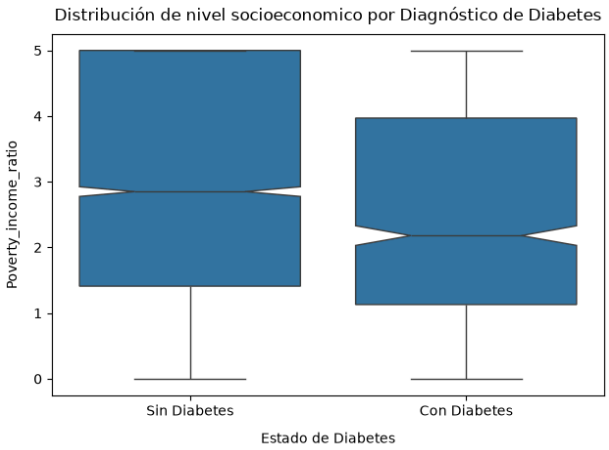
Explicación de la Hipótesis:

H_0 La proporción de diagnósticos positivos de diabetes es independiente del nivel de ingresos familiares (PIR).

H_1: La proporción de diagnósticos de diabetes es significativamente mayor en los estratos de menores ingresos socioeconómicos.

Estrategia de Abordaje: Se seleccionó la población adulta ($\geq$ 18 años) con registros válidos en diabetes_diagnosed y poverty_income_ratio. La variable cuantitativa poverty_income_ratio se discretiza en 4 estratos socioeconómicos (Bajo $[0, 1)$, Medio-Bajo $[1, 2)$, Medio-Alto $[2, 4)$ y Alto $[4, 5.01]$). Se evaluó la prevalencia porcentual con un gráfico de barras, la distribución del PIR según diagnóstico mediante un boxplot, y se ejecutó una Prueba de Independencia de χ^2 de Pearson ($\alpha = 0.05$) sobre la tabla de contingencia construida.





Resultados Obtenidos: Se observa una tendencia decreciente en la prevalencia de diabetes a medida que se asciende en el estrato socioeconómico. El gráfico de Boxplot muestra que la mediana del ratio de pobreza es notablemente inferior en el grupo diagnosticado con diabetes.

En resumen, mientras que el ingreso aumenta, la cantidad de personas que tienen diabetes diagnosticada disminuye. Además de hablar sobre la asignación de recursos a personas con menos ingresos, también podemos mencionar a la alimentación de las personas con un ingreso menor y cómo esto influye en su salud.

Estadístico de prueba: $\chi^2 = 48.1212$.

Grados de libertad: 3.

p-valor: 2.0067×10^{-10} ($p < 0.05$).

Resultado del estudio: SE CONFIRMA LA HIPÓTESIS (SE RECHAZA H_0).

3.3. Hipótesis Bivariada 2:

"La mayoría de los casos de CKD identificados corresponde a blancos no-hispánicos."

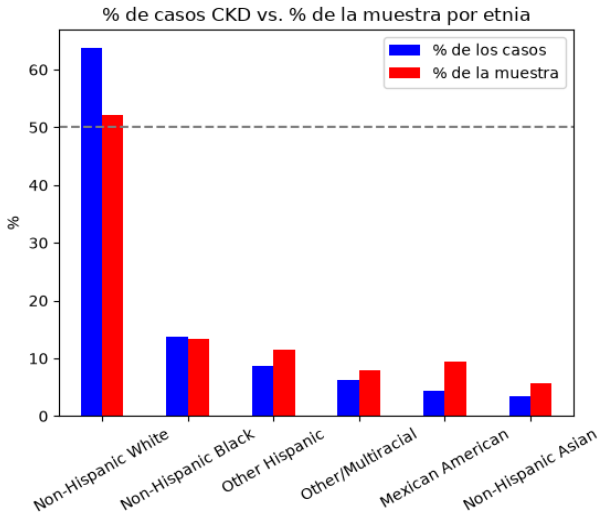
Motivación: Comprender si la Enfermedad Renal Crónica (CKD) afecta de manera desproporcionada a determinados grupos étnicos en los Estados Unidos, lugar donde se realizó la encuesta, lo que permite evaluar disparidades raciales en salud y enfocar campañas en el área mencionada.

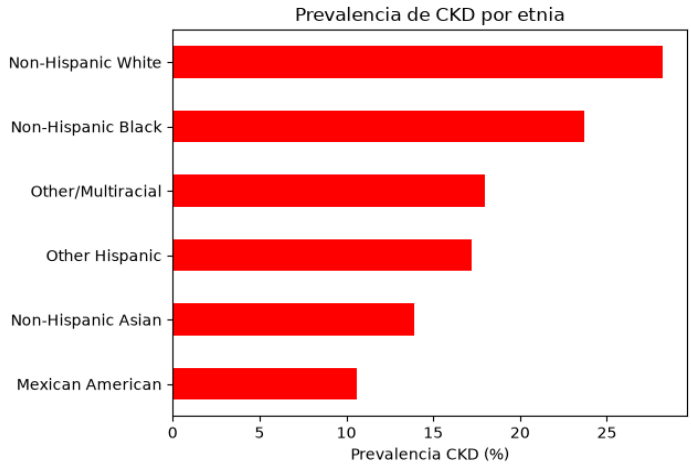
Explicación de la Hipótesis:

- H_0La presencia de CKD es independiente del grupo étnico del participante.

- H_1 Existe una asociación significativa entre la etnia y la presencia de CKD, siendo la etnia Blanca No-Hispánica (*Non-Hispanic White*) la que concentra la mayor cantidad y proporción de casos identificados.

La estrategia de abordaje: Se filtraron los pacientes con presencia confirmada de la enfermedad (ckd_present == 1) y se cruzaron con la variable categórica ethnicity. Se construyó una tabla que resume la cantidad de casos absolutos, el porcentaje del total de casos, el tamaño muestral por etnia y la prevalencia intragrupo. Visualmente se compararon el porcentaje de casos vs. participación muestral (gráfico de barras grupales) y las tasas de prevalencia (gráfico de barras horizontales). Para la validación estadística formal, se realizó una Prueba de Independencia de χ^2 ($\alpha = 0.05$) sobre la matriz completa de ethnicity vs ckd_present.





Resultados Obtenidos:

- El grupo *Non-Hispanic White* registró 1.741 casos, representando el **63,7%** de todos los casos de CKD identificados en el estudio. Asimismo, lideró la tasa de prevalencia interna con un **28,2%** de sus miembros afectados. Una posible explicación es que de la muestra tomada, el grupo *Non-Hispanic White* tiene una mayor cantidad de casos, por eso llegamos a pensar que la hipotesis podria ser cierta solo por ese hecho, pero al evaluar la cantidad de casos y los n de la muestra, vemos que *Non-Hispanic White* sigue siendo el grupo que en proporción presenta más casos de CKD.
- **Estadístico de prueba:** $\chi^2 = 198.8623$.
- **Grados de libertad:** 5.
- p**-valor:** 4.9750×10^{-41} ($p < 0.05$).
- **Resultado del estudio: SE CONFIRMA LA HIPÓTESIS (SE RECHAZA** H_0**).**

3.4. Hipótesis Bivariada 3:

"La presión arterial sistólica elevada está asociada con una mayor presencia de Enfermedad Renal Crónica (CKD)".

Motivación: La presión arterial elevada es uno de los factores de riesgo asociados a la enfermedad renal crónica. Esto se debe a que la hipertensión puede dañar los vasos sanguíneos de los riñones y afectar su capacidad de filtrado.

El objetivo de esta hipótesis es evaluar si las personas con CKD presentan valores de presión arterial sistólica significativamente mayores que aquellas sin la enfermedad. Identificar esta relación permite comprender la importancia del control de la presión arterial para la prevención y detección temprana de problemas renales.

Formulación de hipótesis

- H_0 (Hipótesis nula): La presión arterial sistólica no presenta diferencias significativas entre personas con y sin CKD.
- H_1 (Hipótesis alternativa): La presión arterial sistólica es significativamente mayor en personas con CKD.

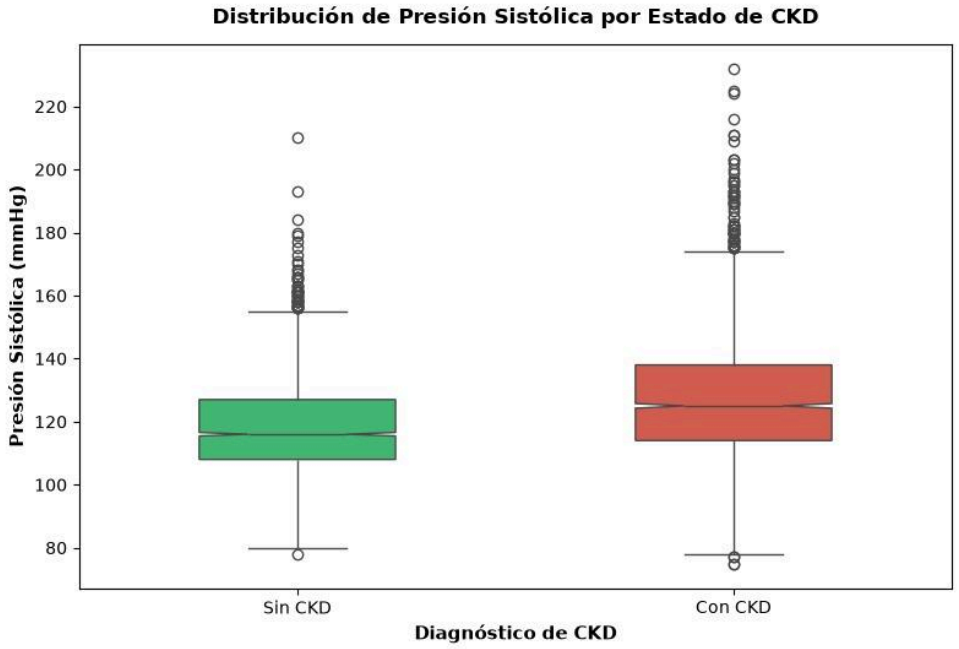
Estrategia de abordaje

Para evaluar la hipótesis utilizamos dos variables del dataset:

- bp_systolic: Variable cuantitativa continua que representa la presión arterial sistólica medida en mmHg.
- ckd_present: Variable categórica binaria que indica la presencia de enfermedad renal crónica (0 = Sin CKD, 1 = Con CKD).

Primero seleccionamos a los participantes mayores o iguales a 18 años y eliminamos los registros con valores nulos en alguna de las dos variables.

Luego construimos un boxplot para comparar la distribución de la presión arterial sistólica entre las personas con y sin CKD.



Para determinar qué prueba estadística utilizar, evaluamos el supuesto de normalidad mediante el test de Shapiro-Wilk. Como los resultados indicaron que las distribuciones no cumplían dicho supuesto, utilizamos el test no paramétrico U de Mann-Whitney, que permite comparar dos grupos independientes sin exigir una distribución normal.

La prueba se realizó con un nivel de significancia de $\alpha = 0,05$ y una hipótesis alternativa unilateral, buscando determinar si los valores de presión arterial sistólica eran mayores en el grupo con CKD.

Resultados obtenidos

El test de Shapiro-Wilk arrojó los siguientes resultados:

- Sin CKD: p-valor = 0,000017441.
- Con CKD: p-valor = 0,000000065567.

En ambos grupos el p-valor fue menor a 0,05, por lo que se rechazó el supuesto de normalidad.

Posteriormente, aplicamos el test U de Mann-Whitney y obtuvimos:

- Estadístico U: 4.775.966.
- p-valor: $3,1088 \times 10^{-76}$.
- Nivel de significancia: $\alpha = 0,05$.

Como el p-valor obtenido es considerablemente menor a 0,05, rechazamos la hipótesis nula (H_0).

Esto indica que existe evidencia estadísticamente significativa de que la presión arterial sistólica tiende a ser mayor en las personas con CKD que en aquellas sin la enfermedad.

3.5. Hipótesis Multivariada 1:

"Existe una asociación entre la edad, el sexo, el índice de masa corporal (IMC), la presión arterial, la diabetes, el tabaquismo y el nivel socioeconómico con la probabilidad de presentar Enfermedad Renal Crónica (CKD)."

Motivación: La Enfermedad Renal Crónica es una afección multifactorial donde convergen determinantes biológicos, clínicos y socioeconómicos. Evaluar cada factor de forma aislada puede generar asociaciones falsas o ignorar efectos de confusión; por ello, un abordaje multivariado permite aislar el efecto independiente de cada variable sobre el riesgo de padecer CKD cuando todas las demás se mantienen constantes.

Explicación de la hipótesis:

H_0: Ninguna de las variables predictoras (edad, sexo, BMI, presión arterial sistólica, diabetes, tabaquismo y ratio pobreza/ingreso) presenta un efecto directo y significativo sobre la probabilidad de tener CKD ($\beta_1 = \beta_2 = ... = \beta_k = 0$.)

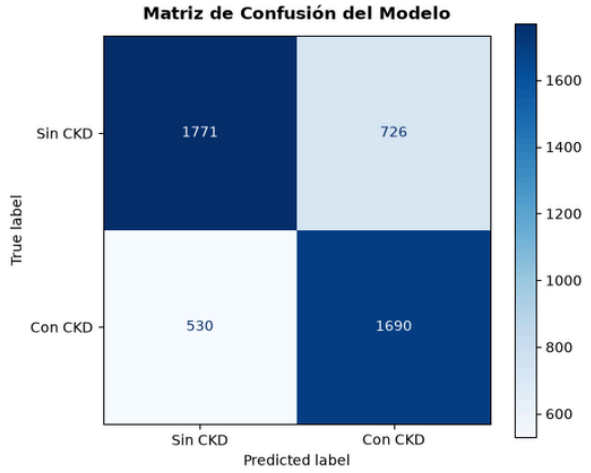
H_1: Al menos una de las características demográficas, clínicas o socioeconómicas mantiene un vínculo estadísticamente significativo ($\beta_j \neq 0$) con la presencia de CKD en presencia de las demás variables.

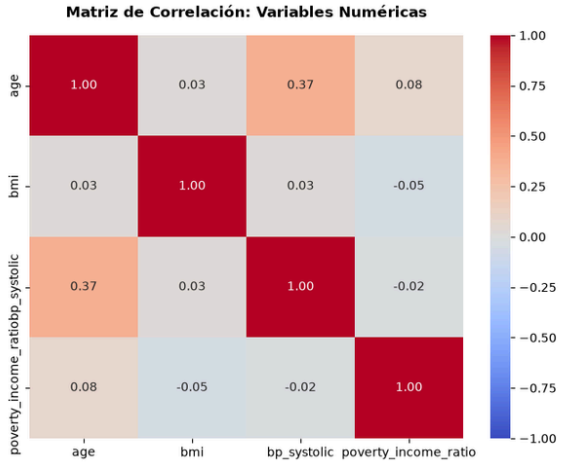
Estrategia de abordaje: Se definió como variable objetivo binaria a ckd_present (0: Sin CKD, 1: Con CKD). Como predictoras se seleccionaron variables cuantitativas (age, bmi, bp_systolic, poverty_income_ratio) y categóricas (gender, diabetes_diagnosed, ever_smoked), eliminando filas con valores nulos (dropna()). Las categóricas se transformaron a variables dummy (drop_first=True).

Previo al ajuste, se construyó una matriz de correlación de Pearson sobre las predictoras numéricas para descartar correlaciones altas ($|r| < 0.7$) que pudieran distorsionar las estimaciones. Se ajustó un modelo de **Regresión Logística Multivariada (Logit)** mediante máxima verosimilitud. La capacidad clasificatoria se evaluó mediante la matriz de confusión y el cómputo de la exactitud global (*Accuracy*).

```
 REVISIÓN DE MULTICOLINEALIDAD
Regla: Si hay valores > 0.7 o < -0.7, esas variables están muy correlacionadas y podría ser un problema.
Optimization terminated successfully.
         Current function value: 0.534081
         Iterations 6

 RESUMEN DEL MODELO DE REGRESIÓN LOGÍSTICA
                           Logit Regression Results
==============================================================================
Dep. Variable:            ckd_present   No. Observations:                 4717
Model:                          Logit   Df Residuals:                     4708
Method:                           MLE   Df Model:                            8
Date:                Sun, 08 Nov 2026   Pseudo R-squ.:                0.2276
Time:                        14:35:03   Log-Likelihood:               -2519.3
converged:                       True   LL-Null:                      -3261.4
Covariance Type:            nonrobust   LLR p-value:                     0.000
===============================================================================
                              coef    std err          z      P>|z|      [0.025      0.975]
-------------------------------------------------------------------------------
const                      -5.3438      0.336    -15.916      0.000      -6.002      -4.686
age                         0.0717      0.003     28.497      0.000       0.067       0.077
bmi                         0.0143      0.005      2.874      0.004       0.005       0.024
bp_systolic                 0.0091      0.002      4.376      0.000       0.005       0.013
poverty_income_ratio       -0.0263      0.022     -1.218      0.223      -0.069       0.016
gender_Male                -0.0032      0.071     -0.045      0.964      -0.142       0.136
diabetes_diagnosed_2.0     -0.1060      0.103     -1.027      0.304      -0.308       0.096
diabetes_diagnosed_3.0     -0.3379      0.199     -1.696      0.090      -0.728       0.053
ever_smoked_2.0            -0.0026      0.072     -0.036      0.971      -0.143       0.138
===============================================================================
```





Resultados Obtenidos:

La correlación lineal máxima observada entre predictores numéricos fue entre edad y presión arterial sistólica (r = 0.37), ubicándose muy por debajo del umbral crítico (|r| < 0.7), descartando redundancia o multicolinealidad severa.

El modelo converge exitosamente con N = 4.717 observaciones. El estadístico de razón de verosimilitud arrojó un p-valor significativo (LLR p-value = 0.000 < 0.05), confirmando que el conjunto de predictores aporta información sustancial frente a un modelo nulo. El r-squared obtenido fue de 0.2276 (22,8%), un valor sólido y representativo para variables biomédicas.

El modelo alcanzó una exactitud del 73,3%. La matriz de confusión reportó:

- Verdaderos negativos (sanos clasificados correctamente): 1771.
- Verdaderos positivos (ckds detectados): 1690.
- Falsos positivos: 726.
- Falsos negativos: 530.

Variables Significativas

Aclaración: Se ajustó un modelo de **Regresión Logística Multivariada**. Este modelo estima los **Log-Odds**, es decir, el logaritmo natural de la razón de probabilidades entre que ocurra el evento y no ocurra, un coeficiente positivo ($\beta > 0$)indica una asociación directa que incrementa la probabilidad de presentar CKD. Esto lo aclaramos porque en una **regresión logística**, la variable dependiente Y es dicotómica (0 o 1), por lo que el modelo no predice Y directamente ni predice la probabilidad $P(Y = 1)$ de forma lineal, sino en una función logarítmica.

Analizando la tabla de regresión (columna P>|z|), identificamos las variables que tienen un vínculo estadísticamente significativo con la presencia de CKD:

1. **Edad (age) β = 0.0717 (z = 28.497, p < 0.001):**
    - **Efecto positivo y altamente significativo.** A mayor edad, se incrementa significativamente el riesgo de presentar CKD, siendo la variable con mayor estadístico de prueba (z = 28.497)
2. **Presión Arterial Sistólica (bp_systolic) β = 0,0091, p < 0,001:**
    - **Efecto positivo y significativo.** Manteniendo constantes el resto de las variables (como edad e ingresos), un incremento en la presión arterial sistólica aumenta de forma independiente la probabilidad de diagnóstico de CKD (z = 4.376).
3. **Índice de Masa Corporal (bmi) β = 0,0143, p = 0.004:**
    - **Efecto positivo y significativo.** Un mayor BMI se asocia a un leve incremento en la probabilidad de CKD (z = 2.874).

Variables NO Significativas

- **Nivel Socioeconómico (poverty_income_ratio, p = 0.223):** No muestra un efecto directo significativo al estar controlado por las variables clínicas.
- **Sexo (gender_Male, p = 0.964):** No existen diferencias estadísticamente significativas entre hombres y mujeres en la presencia de CKD bajo este modelo.
- **Tabaquismo (ever_smoked_2.0,p = 0.971):** En esta muestra multivariada, haber fumado no aportó una diferencia significativa.

- **Diabetes (diabetes_diagnosed):** Las categorías de no diabético (2.0, p = 0.304) y borderline (3.0, p = 0.090) no mostraron diferencias estadísticamente significativas respecto a la categoría de referencia (diabéticos diagnosticados 1.0).

Conclusión

La hipótesis se confirma **parcialmente**: Existe un vínculo directo, positivo y estadísticamente significativo entre la edad, la presión arterial sistólica y el índice de masa corporal con la probabilidad de padecer Enfermedad Renal Crónica. Por el contrario, el nivel socioeconómico, el sexo y el tabaquismo pierden relevancia como predictores directos una vez que se controlan los factores clínicos y biológicos basales.

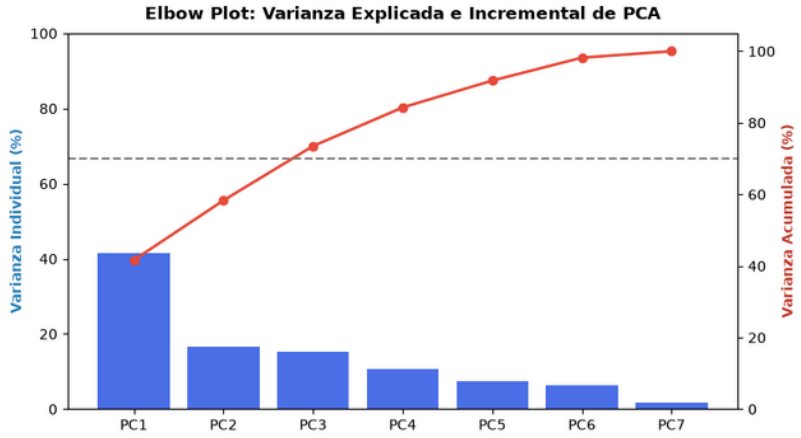
3.6. Hipótesis Multivariada 2:

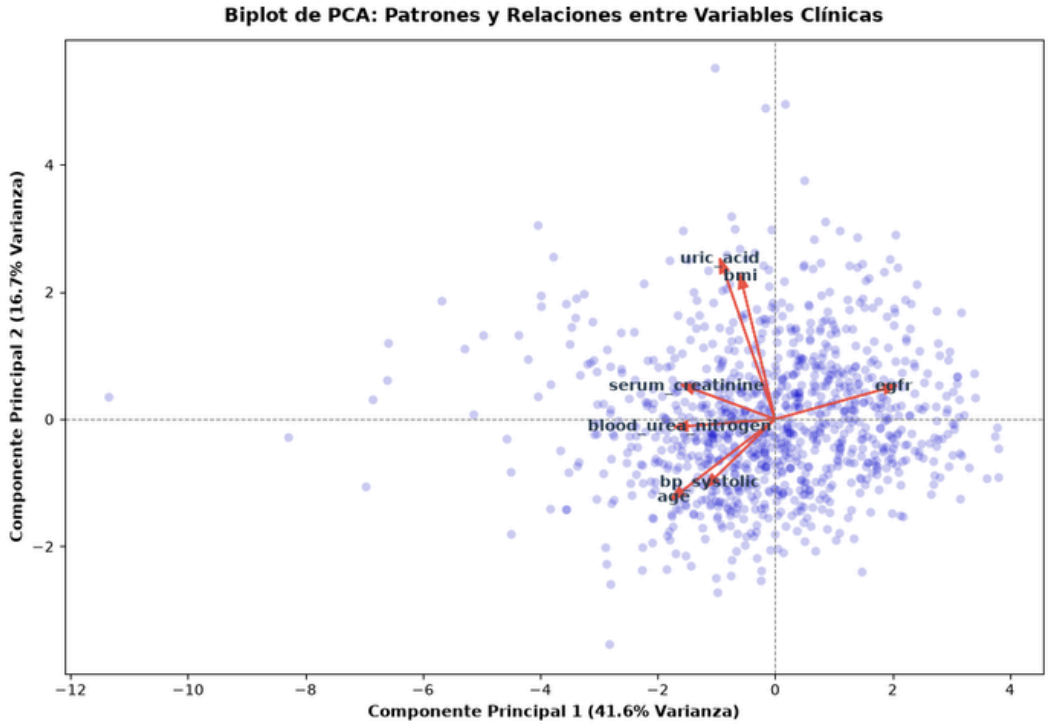
"Los indicadores de salud física (como el peso y la presión arterial) y los marcadores de análisis de laboratorio (como la función de los riñones) se agrupan en patrones comunes que nos permiten ver qué variables se mueven juntas en la población."

Motivación: En el ámbito de la salud, comprender cómo interactúan las variables físicas y los análisis de laboratorio permite identificar tempranamente perfiles de riesgo. El uso de componentes principales permite reducir la dimensionalidad de las observaciones, identificando cómo se interrelacionan estos factores biológicos en un espacio reducido sin limitarse a predecir un único resultado aislado.
Explicación de la Hipótesis:

- H0: Las variables clínicas y de laboratorio varían de forma independiente y aleatoria, sin conformar ejes latentes o agrupamientos biológicos claros.
- H1: Existen patrones de covarianza compartida que permiten condensar la información en dimensiones menores, identificando grupos de variables clínicas que se mueven conjuntamente en la población.

Estrategia de Abordaje: Se seleccionaron 7 variables cuantitativas continuas relevantes: age, bmi, bp_systolic, serum_creatinine, blood_urea_nitrogen, uric_acid y egfr. Se eliminaron los valores nulos con dropna(). Al tratarse de mediciones con distintas escalas, se aplicó una estandarización previa (Z-score). Se aplicó la técnica de Análisis de Componentes Principales (PCA). Se analizó el porcentaje de varianza explicada individual y acumulada para los componentes mediante una tabla y un gráfico de codo (Elbow Plot) con línea umbral en el 70%. Para evaluar la interdependencia y agrupamiento de las variables, se construyó un Biplot proyectando los vectores sobre una muestra aleatoria de 1.000 puntos del dataset.





Resultados Obtenidos:

- Varianza Explicada:
  - Componente Principal 1 (PC1): Explica el 41.63% de la variabilidad total.
  - Componente Principal 2 (PC2): Explica el 16.69% de la variabilidad total.
  - Varianza Acumulada en 2 dimensiones (PC1 + PC2): 58.31% .
  - Detalle de varianza acumulada por componentes: PC1 (41.63%), PC2 (58.31%), PC3 (73.51%), PC4 (84.29%), PC5 (91.80%), PC6 (98.20%), PC7 (100.00%).

La varianza explicada por las dos primeras componentes se sitúa por debajo de la recomendación general del 70%, lo que evidencia patrones no lineales o una alta dimensionalidad en los datos clínicos. Si bien agrega un tercer componente alcanzaría el 73.51%, dificulta la representación gráfica directa.

Interpretación del Biplot (Patrones entre las variables): Al analizar la orientación y dirección de los vectores en el gráfico, se observan tres agrupaciones clínicas definidas:

- Deterioro Renal (Eje Horizontal - PC1): La flecha de egfr (filtrado glomerular) se orienta en dirección opuesta (180 grados) respecto a serum_creatinine y blood_urea_nitrogen. Esto refleja la relación biológica lógica: a menor capacidad de filtrado renal, mayor es la concentración de productos de desecho en sangre.
- Perfil Metabólico (Eje Vertical Superior - PC2): Los vectores de bmi (índice de masa corporal) y uric_acid (ácido úrico) presentan un ángulo muy pequeño entre sí, indicando una correlación positiva directa entre el exceso de peso y los niveles de ácido úrico.
- Cardiovascular / Edad (Eje Vertical Inferior - PC2): Las variables age (edad) y sbp systolic (presión arterial sistólica) apuntan en una misma dirección, evidenciando que el incremento en la presión arterial se encuentra estrechamente ligado al envejecimiento.

Resultado del estudio: Tenemos evidencia suficiente para confirmar la hipótesis. El PCA confirma de manera visual la existencia de tres patrones o dimensiones biológicas independientes en los datos: la función de filtrado renal, el componente corporal metabólico y el factor de envejecimiento y presión arterial. Aunque la proyección en dos dimensiones retiene el 58.31% de la información, el análisis confirma que los marcadores clínicos se mueven conjuntamente en grupos bien delimitados dentro de la población.

4. Conclusiones

A lo largo de este trabajo realizamos un análisis exploratorio y estadístico de un conjunto de datos de 11.933 participantes, con el objetivo de comprender los factores asociados a la Enfermedad Renal Crónica (CKD) y evaluar las relaciones entre distintas variables demográficas, socioeconómicas y clínicas.

En primer lugar, el análisis exploratorio nos permitió comprender la importancia de revisar y preparar los datos antes de realizar cualquier estudio estadístico. Encontramos una cantidad considerable de valores nulos, principalmente relacionados con la edad y la ausencia de participantes en los exámenes. Esto nos llevó a tomar decisiones de limpieza y filtrado, evitando imputación de valores faltantes.

En cuanto a las hipótesis planteadas, encontramos resultados relevantes: Análisis univariado: Confirmamos que el exceso de peso predomina en la población adulta evaluada, ya que el 71,9% presenta sobrepeso u obesidad. Este resultado es importante considerando que el exceso de peso está asociado con distintos problemas de salud.

Análisis bivariados: Encontramos una asociación estadísticamente significativa entre el nivel socioeconómico y el diagnóstico de diabetes, observando una mayor proporción de diagnósticos en los sectores de menores ingresos. También identificamos diferencias significativas en la presencia de CKD según el grupo étnico, siendo los blancos no hispánicos quienes concentraron la mayor cantidad de casos y la mayor prevalencia dentro de la muestra. Por último, observamos que las personas con CKD presentan valores de presión arterial sistólica significativamente mayores que aquellas sin la enfermedad.

Análisis multivariado mediante regresión logística: Pudimos identificar que la edad, la presión arterial sistólica y el índice de masa corporal presentan asociaciones positivas y significativas con la presencia de CKD. Sin embargo, otras variables como el nivel socioeconómico, el sexo, la diabetes y el tabaquismo no mostraron asociaciones significativas dentro del modelo.

Análisis de Componentes Principales (PCA): Logramos identificar patrones de relación entre distintas variables clínicas. Observamos asociaciones entre los indicadores de función renal, entre el IMC y el ácido úrico, y entre la edad y la presión arterial sistólica. Las primeras dos componentes explicaron el 58,31% de la variabilidad total, lo que indica que una representación bidimensional permite visualizar parte de estas relaciones, aunque no alcanza para representar toda la información del conjunto de datos.

Aprendimos que la correlación no implica causalidad. Como vimos en clase con el ejemplo de la venta de helados y los ataques de tiburones, dos variables pueden estar relacionadas sin que una sea la causa de la otra. Por eso, nuestros resultados permiten identificar asociaciones, pero no establecer relaciones de causa y efecto.

Finalmente, consideramos que el trabajo permitió cumplir con el objetivo inicial de explorar el conjunto de datos, identificar problemas de calidad y estudiar factores de la enfermedad renal crónica. A partir de las diferentes herramientas utilizadas, pudimos comprobar ciertas hipótesis, y reconocer que no todas las variables tienen la misma importancia al analizarlas de manera conjunta.

Como conclusión general, la edad, la presión arterial y el exceso de peso se destacan como variables relevantes dentro de nuestros análisis, mientras que los resultados socioeconómicos y demográficos muestran la importancia de considerar diferentes dimensiones al estudiar problemas de salud. Este trabajo también nos permitió comprender que la calidad de los datos, la elección de las herramientas estadísticas y la interpretación crítica de los resultados son fundamentales para obtener conclusiones confiables en Ciencia de Datos.

Referencias

CDC/NCHS, NHANES 2021-2023:
https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023

CDC/NCHS, Brief Overview of Sample Design:
https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/overviewbrief.aspx?Cycle=2021-2023

NCHS, Response Rates Aug 2021–Aug 2023:
https://wwwn.cdc.gov/nchs/data/ResponseRates/NHANES-August-2021-August-2023-Response-Rates.pdf